

自然语言处理 19-20 秋季课程作业

多轮对话综述：过去、现在与应用

曾四为
中国科学院大学

对话系统旨在使机器能够通过自然语言与人类沟通，从而充当虚拟助手和智能客服等角色来为人们提供生活中的便利性。在自然语言处理领域，对话系统是一个广受关注的研究方向。随着深度学习的发展，对话系统能够利用大规模数据深层次地学习语句的特征表示和回复策略，展现出越来越大的应用潜力。本文沿着研究的发展历史来全面总结对话系统各个阶段的模型，并对当前工业级对话系统应用模型进行简单地描述。

1. 引言

自从 1950 年图灵提出正式的人工智能测验 (Turing 1950) 后，创建一个能够和人自然、流畅交流的对话系统就成为自然语言处理领域的一个重要目标，同样也是一项具有挑战性的工作。

对于对话系统，根据不同的分类标准，有不同的划分方式。根据其应用领域，可以分为问答对话系统、闲聊对话系统和任务对话系统 (Chen et al. 2017a)；根据其涉及的领域，可以分为开放领域对话系统和垂直领域对话系统；根据其是否使用历史对话信息，可以分为单轮对话系统和多轮对话系统 (Shang, Lu, and Li 2015; Mou et al. 2016)；根据研究的发展历史和系统构建方式，可以分为第一代基于符号规则和模版的对话系统、第二代基于管道的对话系统和第三代大数据驱动的对话系统。

1.1 问题描述

对话系统的形式化描述为：每一次用户与计算机的交互会话中，都是用户以一句自然语言所构成的话语作为输入（也可称为查询），计算机返回一句用户可以理解的回答。多轮对话系统会利用会话中的历史对话信息，而单轮对话系统只根据当前用户输入给出回答。

记用户的输入为 q ，系统的回复为 r ，对话历史信息为 c ，对话系统的回复获取过程为 f ：

- 对于单轮对话系统有： $r = f(q)$
- 对于多轮对话系统有： $r = f(q, c)$

对于不同的对话系统，主要有三种回复获取方式：通过对话状态根据模版进行回复的填充和生成；将查询与语料库中的查询-回复对进行匹配，通过检索返回匹配度最高的结果；通过文本生成的方法，根据查询生成出对应回答。

1.2 本文框架

本文旨在(1)按照对话系统的发展历史,对对话系统进行全面的回顾分析;(2)对工业界对话系统进行简要介绍。本文在第2节介绍基于符号规则和模版的对话系统;第3节介绍传统统计模型以及当前流行的深度模型在基于管道的对话系统中的应用;第4节梳理大数据驱动下对话系统的两种端对端构建方法;第5节介绍当前工业界对话系统的设计架构;第6节是总结。

2. 第一代：基于符号规则和模版的对话系统

最早期对于对话系统的研究 (Weizenbaum 1966; Wilensky et al. 1988) 集中在基于符号规则和模版的对话系统方向。对话系统通过人工规则对用户语句进行匹配,之后根据模版作出回应。

这类系统 (Epstein, Roberts, and Beber 2008; das Graças Bruno Marietto et al. 2013) 依赖于专家人工语法规则,具有规则解释性好、系统易编写易维护、漏洞易修正的优点。但是其缺点主要有三点:一是依赖于专家的人工规则设计,专家水平和规则质量高低严重影响系统质量,二是难以跨领域迁移,只能针对狭窄的垂直领域,三是构架成本高,需要消耗大量人力资源和时间成本。

3. 第二代：基于管道的对话系统

基于管道的对话系统的典型结构如图1所示,包含自然语言理解模块、对话状态追踪模块、对话规则学习模块和自然语言生成模块四个基本组件 (Rudnicky et al. 1999; Zue et al. 2000; Zue and Glass 2000)。自然语言理解模块将用户的语句转换成预定义的意图和语义槽。对话状态追踪模块根据当前语句和对话历史,输出当前的对话状态;对话规则学习模块会基于当前的状态,执行相应的系统行为;自然语言生成模块根据系统行为的返回结果,生成用户能够理解的语句。对话状态追踪模块和策略学习模块也被合称为对话管理模块。

基于统计的管道对话系统因为将人工规则和统计数据相结合,也被称为“数据驱动的对话系统”或“基于浅层学习的对话系统”。得益于统计模型的应用,对话系统极大的减少了编写大量人工规则所带来的成本,并可以通过新的数据提升系统的表现。但是统计对话系统一方面不容易理解和修补漏洞,另一方面学习能力不强,不能生成出符合人们预期的回复。

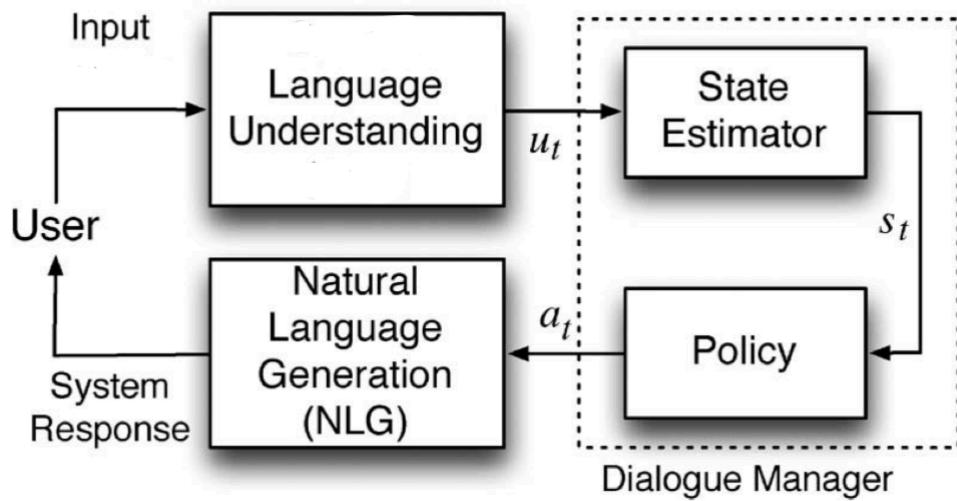


图 1: 基于管道的对话系统架构图

随着深度学习应用到 NLP 的各个领域, 统计对话系统中各个模块的统计学习模型也逐渐被深度学习替代, 但四个组件的整体结构没有变化。(Zhao and Eskenazi 2016) 提出第一个使用端到端强化学习方法来训练对话管理模块的模型。(Wen et al. 2017) 和 (Bordes, Boureau, and Weston 2017) 构建端到端的任务对话系统。

3.1 自然语言理解模块

自然语言理解模块需要根据用户问句提取出句子层次和词汇级别两个层次的信息, 句子层次的信息包含句子的主题以及用户目的, 而词汇级别的信息包含命名实体、动作的施事方和受事方等等。

3.1.1 意图检测. 意图检测是指根据用户的语句, 将其划分到预定义的某一个意图类中, 从而起到检测用户意图的目的。研究人员使用的传统统计模型有朴素贝叶斯分类器、逻辑斯特回归分类器、决策树模型和支持向量机等。

深度学习的技巧已经成功的应用到意图检测任务中。研究人员使用 DBN(Sarikaya, Hinton, and Ramabhadran 2011)、DCN(Tur et al. 2012)、kernel DCN(Deng et al. 2012)、RNN(Ravuri and Stolcke 2015) 和 CNN(Xu and Sarikaya 2013) 等深度模型来完成对用户语句的潜在意图识别。

3.1.2 槽填充. 槽填充是指将用户语句中的每个词标注上一个语义标签, 通常被认为是序列标注问题。对于一个输入和句子, 经过槽填充过程后会得到一个等长的标签序列。

研究人员使用条件随机场 (Wang and Acero 2006; Raymond and Riccardi 2007)、DBN(Deoras and Sarikaya 2013) 和 RNN(Yao et al. 2013; Mesnil et al. 2013) 等模型来完成槽填充任务。(Simonnet et al. 2015) 引入编码解码器结构和注意力机制来编码语句。(Liu and Lane 2016) 将意图检测和槽填充任务结合, 通过序列到序列模型或基于注意力机制的 RNN 所得到的隐状态同时完成两项任务。(Zhai et al. 2017) 结合指针网络, 使得模型能够实现词组级别的槽位识别。

在经典数据集上 (Hemphill, Godfrey, and Doddington 1990; Dahl et al. 1994), 许多深度模型 (Liu and Lane 2016; Zhai et al. 2017) 都达到了 95% 的准确性。为了进一步评估模型的能力, 在槽填充领域还需要更多样化、更大规模的数据集。

3.2 对话状态跟踪模块

对话状态跟踪是确保对话系统健壮性的核心组件, 通过被称为语义框架的状态结构来维护用户的当前会话状态。具体来说, 会话状态是通过对话历史、用户意图和槽值对构成的语义框架来描述。对话跟踪模块根据每一轮次新的输入, 对当前用户的状态进行更新, 管理每个回合的输入和对话历史, 输出当前对话状态。

基于规则的模块构建方法已经在大多数商业实现中得到了广泛的应用, 通常采用手工规则来选择最有可能的输出结果 (Goddeau et al. 1996)。然而, 基于规则的模块容易出现频繁的错误, 因为实际对话往往不会按照人为设计的流程发展 (Williams 2013)。

基于统计的状态跟踪模块会根据当前会话状态对真实的对话状态计算一个概率分布 (Williams et al. 2013), 用来处理充满噪音或模糊语义的情况。多种统计方法都被使用, 包括人工规则 (Wang et al. 2013)、条件随机场 (Ren et al. 2013; Lee 2013; Kim and Banchs 2014)、最大熵模型 (Williams 2013) 和基于随机游走 (Williams 2014) 的排序模型。

(Henderson, Thomson, and Young 2013) 利用 DNN 在时间窗口内对多轮状态提取的特征。(Mrkšić et al. 2015) 用 RNN 进行多领域的对话状态追踪, 并证明利用多个领域的数据有助于模型表现提升。(Mrksic et al. 2017) 通过将所有槽位和当前状态经过编码后的语义表示逐一进行相关性二分类。

3.3 策略学习模块

策略学习根据状态跟踪器的状态表示生成下一个可用的系统动作 (action)。在线购物场景中，如果对话状态是“推荐”，那么触发“推荐”操作，系统将从产品数据库中检索产品。

无论是人工规则、监督学习还是强化学习都可以用来优化策略学习 (Cuayáhuitl, Keizer, and Lemon 2015)。然而，基于规则的模块面对巨大的状态空间容易出现错误 (Zhou et al. 2017)。

监督学习方法通过有标签数据对决策过程进行建模。(Lefevre et al. 2009) 使用 k 近邻、蒙特卡罗算法和部分可观察马尔可夫决策过程来建模决策过程。(Gasic and Young 2014) 使用高斯过程和部分可观察马尔可夫决策过程来建模决策过程。

强化学习方法的引入 (Jurčiček, Thomson, and Young 2011; Wen et al. 2017; Su et al. 2017) 可以对对话策略进行进一步的训练，以引导系统制定最终的策略。在实际实验中，强化学习方法的效果超过了基于规则和监督的方法。

3.4 自然语言生成模块

自然语言生成在很多自然语言处理任务都有涉及，比如摘要生成、视觉问答、翻译、文章生成、对话系统等。NLG 模块会将抽象的动作以及结果用自然语言的形式表达出来。

(Reiter 1994) 提出了简单的三步式管道模型：内容确定、句子重组和句表实现。(Reiter and Dale 2000) 进一步完善三步式模型，确定了经典六步式模型：内容确定、文本结构、句子聚合、语法化、参考表达生成和语言实现。内容确定作为自然语言生成的第一步，需要决定哪些信息应该包含在句子中。文本结构将按照逻辑和语言习惯安排内容的顺序。句子聚合将多个信息合并到一个句子中进行表达。语法化会在信息间添加一些连接词，参考表达生成也是类似的工作。最后语言实现将所有相关的单词和短语组织起来，形成一个结构良好的句子。

传统的自然语言生成模块已经逐渐被深度学习端到端的模型所替代。节4.4中的序列到序列模型是经典的文本生成模型。

4. 第三代：大数据驱动的对话系统

第三代大数据驱动的对话系统主要应用模型为基于检索的模型和基于生成的模型，其共同特点是都是端对端的模型，大大降低对话系统的构建成本，并有较好的可迁移性。但大数据驱动的对话系统尚无明确的商业成功案例，系统的解释性低、漏洞难以发现和修补的缺陷依然存在。

表 1: 对话和其他文本匹配任务对比表

Tasks	Text 1	Text 2	Objective	Totally match
Information Retrieval	query	document	ranking	✓
Paraphrase Identification	string 1	string 2	classification	✓
Textual Entailment	text	hypothesis	classification	×
Question Answer	question	answer	ranking	✓
Conversation	dialog	response	ranking	×

4.1 检索式模型

当接收到用户的查询时，检索式模型会从已经构建好的语料库中检索出最为匹配的回答，并返回给用户。具体来说，检索式模型和节4.4中的生成式模型相对比，有着回复语句自然流畅的优点，但是因为语料库的限制，容易出现“牛头不对马嘴”的现象。

(Isbell et al. 2006) 通过在语料库中检索匹配回答的方式，构建一个简易的对话系统。(Wang et al. 2013) 公开了一个基于社交媒体的数据集，并提出两步式结构：第一步是候选检索阶段，通过人工特征使用传统机器学习方法，选择出少量的候选回复，第二部是回复重排序阶段，通过比较语句与候选回复的匹配程度对候选回复进行排序，选取匹配程度最高的回复作为系统回复。(Ji, Lu, and Li 2014) 通过设计词级别和句级别的人工特征，并引入全连接网络来衡量对话匹配程度。

随着深度学习应用到自然语言处理、计算机视觉等领域，各项任务都取得了重大突破 (Goodfellow, Bengio, and Courville 2016)。但对话任务目前仍然极具挑战性，因为和传统的文本匹配任务相比，虽然都是使用两个语句进行匹配程度（或者称关联程度）的计算，但对话的查询和回复还存在话题一致性的问题。例如，对于查询“明天你打算和我去逛街吗”，相应的正确回复“好的，明天天气不错”相比于语义的相同程度，更注重语意的连贯。表1给出了对话与其他匹配任务的对比情况。

随着数据集的规模增大、深度模型参数量增多，越来越多的检索式对话系统通过使用两步式结构来加快模型在大数据集上的训练和预测时间。

4.2 候选检索阶段

候选检索阶段旨在根据查询语句的语言学特点和语义挑选出若干个候选回复。考虑到任务的特点和巨大的检索空间，简单的做法是使用用户查询和语料库查询的语义距离 (Isbell et al. 2006)。

研究人员也通过朴素贝叶斯方法、逻辑斯特回归和决策树模型 (Song et al. 2018) 等来得到候选回复。常见的人工特征有句的分布式表示、句子长度、实体相似性和句法树结构等。

4.3 重排序阶段

重排序阶段旨在利用对话历史和查询语句，在候选回复中挑选出最佳的回复。

(Lowe et al. 2015) 通过直接拼接的方式将历史语句和当前语句编码，然后利用孪生网络将其和候选回复分别编码并计算匹配程度。(Yan, Song, and Wu 2016) 尝试使用多种方式来拼接历史语句和当前语句，然后利用 BiLSTM 和 CNN 提取对话的语义。(Zhou et al. 2016) 采用分层次思路，将历史语句先分别通过 TextCNN 提取出词级别表示，再通过 GRU 得到句级别的历史信息，比之前的简单拼接方式更有效地利用历史语句。

随着文本匹配任务中交互型模型的广泛应用 (Hu et al. 2014; Pang et al. 2016; Chen et al. 2017b)，表示型模型逐渐被交互型模型所替代。表示型模型指的是将对话和候选回复的分别用向量隐式表示，再通过匹配函数计算得到匹配得分。交互型模型关注历史信息 and 候选回复的直接相似性，不通过隐式的方式提取语义，而直接通过构建向量间的相似矩阵来提取匹配信息。

(Wu et al. 2017) 通过历史对话和候选回复的词级别和句级别向量计算得到相似矩阵，再使用 CNN 提取相似矩阵中的关键匹配信息。(Zhang et al. 2018b) 通过 Attention 机制来归纳历史信息向量，解决历史信息存在冗余和噪音的情况。(Zhou et al. 2018) 利用 Transformer 提取出多层次的语句信息，然后对相似度矩阵做三维卷积操作，从而结合多层次、多粒度的信息。(Tao et al. 2019) 引入字符的向量化表示来解决 OOV 问题，并探究在不同阶段进行语义融合对匹配结果的影响。(Qu et al. 2019) 利用预训练模型 BERT 在大语料上训练得到的词法语法句法信息提高模型对对话的表示能力。

4.4 生成式模型

随着深度学习技术的成功，神经网络展现出了学习人类对话模式的强大能力 (Ritter, Cherry, and Dolan 2011)。神经网络也被应用于自然语言生成任务，其旨在通过一个句子生成另一个相关联的句子。

而对于这类任务，序列到序列 (Sequence to Sequence, Seq2Seq) 模型被 (Bahdanau, Cho, and Bengio 2015) 和 (Sutskever, Vinyals, and Le 2014) 先后提出。序列到序列模型的经典结构如图2所示，也被称为编码解码模型。模型的编码器部分接收一段输入文本序列，然后将文本中的潜在信息编码到隐状态 h_i 中，最后输出最终的隐状态 h_t 作为文本的内容向量 c ，解码器则在文本向量 c 的帮助下预测对应的

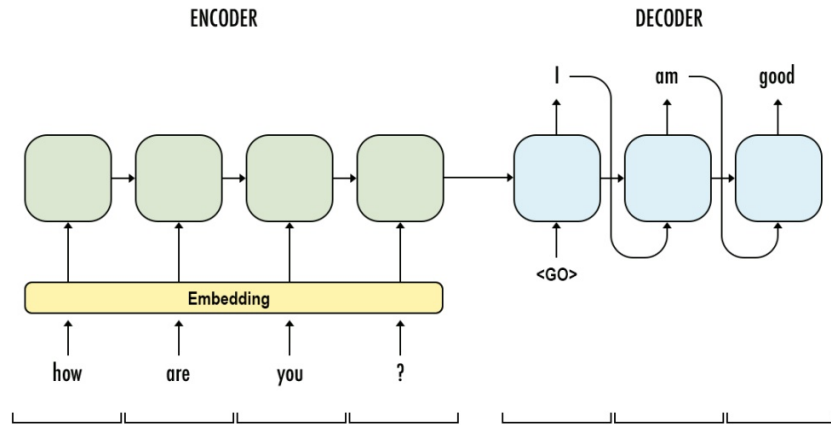


图 2: 序列到序列模型

输出序列。序列到序列模型克服了传统神经网络模型输入语句长度和输出语句长度。(Shang, Lu, and Li 2015) 使用序列到序列模型来完成短文本对话任务。

但是序列到序列模型面临四个困难：模型不能参考历史对话来进行生成回复。模型容易生成大量无意义、通用的语句作为回复。模型没有结合世界知识，很难理解深层次语义。对话系统应该根据对象的不同而采用不同的说话方式。

本文将在后续小结讨论解决这些困难的现有方法。

4.4.1 利用历史信息. 编码具有上下文的信息，例如对话历史，能有效帮助模型生成前后一致、有信息量而且符合具体语境的回答，因为这些信息有助于模型更好地理解问题的语义和语境。但传统 Seq2Seq 模型面临无法对由多个句子构成的对话历史建模的现实困难，由此产生了一系列引入对话历史的模型。

(Sordoni et al. 2015) 通过将历史信息 and 用户查询通过全连接层进行编码，将其作为辅助的历史信息来指导解码器生成回答。(Serban et al. 2016) 提出层次化序列到序列模型，在编码阶段对历史信息进行先后进行词级别编码和句子级编码，从而使得编码器能够在句子层面提取历史信息。(Tian et al. 2017) 比较各种融合对话历史方法的优劣，并指出通过引入对话历史，有利于产生更长、更富信息和更多样化的回复，提高回复质量。(Xing et al. 2018) 使用注意力机制来增强层次化模型对历史信息的提取能力，减少无关噪音。(Serban et al. 2017) 在层次化模型中加入变分自编码器和记忆网络来跟踪对话的长期记忆。

4.4.2 减少无意义语句. 生成式模型始终存在的挑战是其倾向于生成无意义的、缺少信息量的、通用回答 (Li et al. 2016a)。例如，对于任何的用户语句，生成的结果都有可能是“我也觉得”或“我也是这么认为的”这样、可以应用到几乎所有语句的“万能回答”。无论模型在中文数据还是在英文数据上进行训练，这种现象都非常明显。

(Li et al. 2016a) 提出互信息指标来作为生成句子的评价指标, 从而在生成的候选回答中挑选出有意义的回答。(Li et al. 2016b, 2017) 还通过引入强化学习, 将 MMI 作为惩罚项来对生成器生成的无意义或重复语句进行惩罚。(Shao et al. 2017) 引入随机集束搜索来提高模型性能。(Tian et al. 2017) 指出通过引入对话历史, 有利于产生更长、更富信息和更多样化的回复 (Liu et al. 2018b) 通过使用基于统计的句子出现频率作为权重, 来惩罚通用回答。(Song et al. 2018) 提出结合检索模型挑选出的候选回答的方法, 利用复制机制和多层次的 attention 机制来指导回复的生成。

4.4.3 知识图谱. 在人们的对话交流中, 往往会隐含对真实世界的假设。对话系统也需要利用外部知识来增强模型对对话内容的理解和表示能力。而且引入外部知识还能减少无意义语句的生成。

(Mou et al. 2016) 通过词对互信息指标挑选出关键词, 然后将关键词用于指导回复的生成方向。(Xing et al. 2017) 利用 LDA 模型学习对话的主题表示, 再结合注意力机制指导回复生成。(Young et al. 2018) 通过编码外部知识库的实体三元组来辅助对话中涉及实体属性的生成。(Liu et al. 2018a) 提出知识扩散机制, 同时利用知识库中的匹配实体和相似实体。(Zhou et al. 2018) 使用图注意机制来编码实体向量来指导语义提取和词语生成工作。(Dinan et al. 2019) 使用记忆网络和 Transformer 来建模查询、对话历史和实体的交互关系。

4.4.4 个性化系统. 如何让对话系统表现得和人一样是一项极具挑战性的任务。一方面, 人与人之间的语言习惯各有千秋; 另一方面, 在现实人们的日常交流中, 根据对方的身份和偏好来调整谈话的风格和策略是非常自然的行为。面向人类性格的传统研究是基于 BigFive 模型 (Goldberg 1993), 所以早期建立个性化对话系统的工作 (Mairesse and Walker 2007) 同样是基于 BigFive 模型。但是依据 BigFive 来对个性进行描述是非常困难和需要昂贵代价的任务 (Zheng et al. 2019)。

在大数据驱动的文本生成视角下, 替代的方法是通过显式或隐式的用户信息输入来辅助回复的生成, 从而回复具有个性化。而且相较于对话系统自身的固有语言风格, 如何让生成式对话系统根据对话对象的特点和习惯, 理解对象的个性化需求, 从而生成高效、贴切的语句, 成为研究人员更为关注的问题 (Luo et al. 2019)。

(Li et al. 2016a) 通过将用户的向量化表示拼接到输入向量中, 使得生成语句符合用户特点。(Kottur, Wang, and Carvalho 2017) 延续 Li 的思路将模型应用到多轮对话任务上。(Zheng et al. 2019) 通过简易的门机制将解码器输出 y_i 和用户特征向量结合, 得到回复的第 i 个单词。(Luo et al. 2019) 引入用户的属性和相似用户的对话信息, 并使用注意力机制将用户属性的独热表示向量用以指导对对话历史和相似用户对话信息的隐变量表示。

但该任务的难点还存在于现有的大多数数据集都不适用于个性化对话生成任务, (Zheng et al. 2019; Joshi, Mi, and Faltings 2017; Zhang et al. 2018a) 开源针对个性

化任务的对话数据集，解决了传统对话数据集缺少对话者信息标注的问题。(Zhang et al. 2019) 通过迁移学习来让对话系统在不同小规模数据集上学习到不同的语言风格。

5. 工业界对话系统

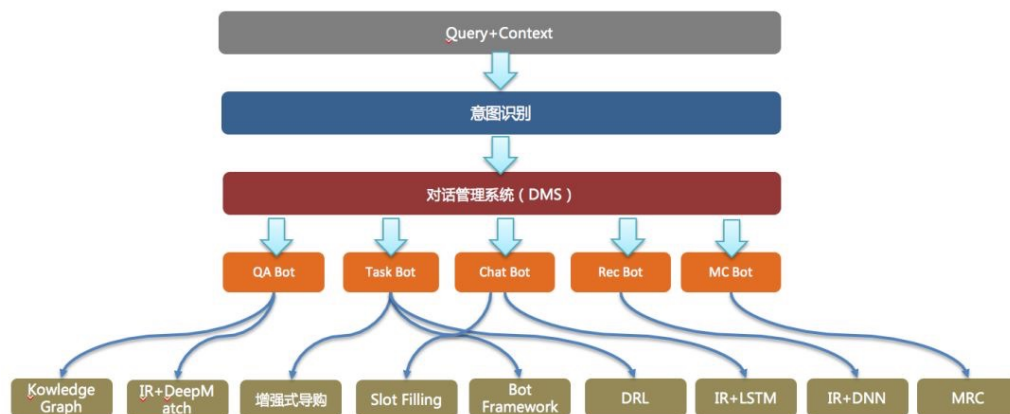


图 3: 阿里小蜜对话系统架构图

面对不同用户的多样化需求,工业界对话系统采用了多层次的管道结构 (Li et al. 2019; Zhou et al. 2018), 如图3所示。通过预先的意图识别模块,将用户导向不同功能的对话系统,从而完成不同难度的语义理解和意图完成工作。对于意图是“闲聊”的用户,通过闲聊型对话系统来基于语料库检索或生成回复 (Zhou et al. 2018)。对于意图是“查询”的用户,通过与外部数据库和知识图谱相连接的问答型对话系统,使用文本匹配方法来检索相应回复模版 (Li et al. 2019)。对于意图是“请求”的用户,通过任务型对话系统基于会话状态来生成回复。

具体的对话系统结构和前文一致。

6. 总结

构建能像人一样与人自然流畅交流的对话系统是人工智能领域的最高目标之一。在人们的日常生活中,对话系统也能发挥出重要作用,如虚拟助手、智能客服等。随着海量数据的产生和深度学习的发展,对话系统迎来了长足的发展。本文沿着对话系统的历史发展脉络,介绍多种对话系统的构建方式,并评价了其优缺点。本文简单介绍了工业界对话系统的架构,尝试为研究人员建立较为完整的研究视角。

References

- Bahdanau, Dzmitry, Kyunghyun Cho, and Yoshua Bengio. 2015. Neural machine translation by jointly learning to align and translate. In *ICLR 2015 : International Conference on Learning Representations 2015*.
- Bordes, Antoine, Y-Lan Boureau, and Jason Weston. 2017. Learning end-to-end goal-oriented dialog. In *ICLR 2017 : International Conference on Learning Representations 2017*.
- Chen, Hongshen, Xiaorui Liu, Dawei Yin, and Jiliang Tang. 2017a. A survey on dialogue systems: Recent advances and new frontiers. *Sigkdd Explorations*, 19(2):25–35.
- Chen, Qian, Xiaodan Zhu, Zhen-Hua Ling, Si Wei, Hui Jiang, and Diana Inkpen. 2017b. Enhanced lstm for natural language inference. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, volume 1, pages 1657–1668.
- Cuayáhuitl, Heriberto, Simon Keizer, and Oliver Lemon. 2015. Strategic dialogue management via deep reinforcement learning. In *NIPS'15 Workshop on Deep Reinforcement Learning*.
- Dahl, Deborah A., Madeleine Bates, Michael Brown, William Fisher, Kate Hunicke-Smith, David Pallett, Christine Pao, Alexander Rudnicky, and Elizabeth Shriberg. 1994. Expanding the scope of the atis task: the atis-3 corpus. In *HLT '94 Proceedings of the workshop on Human Language Technology*, pages 43–48.
- Deng, Li, Gokhan Tur, Xiaodong He, and Dilek Hakkani-Tur. 2012. Use of kernel deep convex networks and end-to-end learning for spoken language understanding. In *2012 IEEE Spoken Language Technology Workshop (SLT)*, pages 210–215.
- Deoras, Anoop and Ruhi Sarikaya. 2013. Deep belief network based semantic taggers for spoken language understanding. In *INTERSPEECH*, pages 2713–2717.
- Dinan, Emily, Stephen Roller, Kurt Shuster, Angela Fan, Michael Auli, and Jason Weston. 2019. Wizard of wikipedia: Knowledge-powered conversational agents. In *ICLR 2019 : 7th International Conference on Learning Representations*.
- Epstein, Robert, Gary Roberts, and Grace Beber. 2008. Parsing the turing test: Philosophical and methodological issues in the quest for the thinking computer.
- Gasic, Milica and Steve Young. 2014. Gaussian processes for pomdp-based dialogue manager optimization. *IEEE Transactions on Audio, Speech, and Language Processing*, 22(1):28–40.
- Goddeau, D., H. Meng, J. Polifroni, S. Seneff, and S. Busayapongchai. 1996. A form-based dialogue manager for spoken language applications. In *Proceeding of Fourth International Conference on Spoken Language Processing. ICSLP '96*, volume 2, pages 701–704.
- Goldberg, Lewis R. 1993. The structure of phenotypic personality traits. *American Psychologist*, 48(1):26–34.
- Goodfellow, Ian, Yoshua Bengio, and Aaron Courville. 2016. *Deep Learning*.
- das Graças Bruno Marietto, Maria, Rafael Varago de Aguiar, Gislene de Oliveira Barbosa, Wagner Tanaka Botelho, Edson P. Pimentel, Robson dos Santos França, and Vera Lúcia da Silva. 2013. Artificial intelligence markup language: A brief tutorial. *International Journal of Computer Science & Engineering Survey*, 4(3):1–20.
- Hemphill, Charles T., John J. Godfrey, and George R. Doddington. 1990. The atis spoken language systems pilot corpus. In *HLT '90 Proceedings of the workshop on Speech and*

- Natural Language*, pages 96–101.
- Henderson, Matthew, Blaise Thomson, and Steve Young. 2013. Deep neural network approach for the dialog state tracking challenge. In *Proceedings of the SIGDIAL 2013 Conference*, pages 467–471.
- Hu, Baotian, Zhengdong Lu, Hang Li, and Qingcai Chen. 2014. Convolutional neural network architectures for matching natural language sentences. In *Advances in Neural Information Processing Systems 27*, pages 2042–2050.
- Isbell, Charles Lee, Michael Kearns, Satinder Singh, Christian R. Shelton, Peter Stone, and Dave Kormann. 2006. Cobot in lambdamoo: An adaptive social statistics agent. *Autonomous Agents and Multi-Agent Systems*, 13(3):327–354.
- Ji, Zongcheng, Zhengdong Lu, and Hang Li. 2014. An information retrieval approach to short text conversation. *arXiv preprint arXiv:1408.6988*.
- Joshi, Chaitanya K., Fei Mi, and Boi Faltings. 2017. Personalization in goal-oriented dialog. *arXiv preprint arXiv:1706.07503*.
- Jurčićek, Filip, Blaise Thomson, and Steve Young. 2011. Natural actor and belief critic: Reinforcement algorithm for learning parameters of dialogue systems modelled as pomdps. *ACM Transactions on Speech and Language Processing*, 7(3):6.
- Kim, Seokhwan and Rafael E. Banchs. 2014. Sequential labeling for tracking dynamic dialog states. In *Proceedings of the 15th Annual Meeting of the Special Interest Group on Discourse and Dialogue (SIGDIAL)*, pages 332–336.
- Kottur, Satwik, Xiaoyu Wang, and Vitor R. Carvalho. 2017. Exploring personalized neural conversational models. In *IJCAI’17 Proceedings of the 26th International Joint Conference on Artificial Intelligence*, pages 3728–3734.
- Lee, Sungjin. 2013. Structured discriminative model for dialog state tracking. In *Proceedings of the SIGDIAL 2013 Conference*, pages 442–451.
- Lefevre, Fabrice, Milica Gašić, Filip Jurčićek, Simon Keizer, François Mairesse, Blaise Thomson, Kai Yu, and Steve Young. 2009. k-nearest neighbor monte-carlo control algorithm for pomdp-based dialogue systems. In *Proceedings of the SIGDIAL 2009 Conference*, pages 272–275.
- Li, Feng-Lin, Weijia Chen, Qi Huang, and Yikun Guo. 2019. Alime kbqa: Question answering over structured knowledge for e-commerce customer service.
- Li, Jiwei, Michel Galley, Chris Brockett, Jianfeng Gao, and Bill Dolan. 2016a. A diversity-promoting objective function for neural conversation models. In *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 110–119.
- Li, Jiwei, Will Monroe, Alan Ritter, Dan Jurafsky, Michel Galley, and Jianfeng Gao. 2016b. Deep reinforcement learning for dialogue generation. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pages 1192–1202.
- Li, Jiwei, Will Monroe, Tianlin Shi, Sébastien Jean, Alan Ritter, and Dan Jurafsky. 2017. Adversarial learning for neural dialogue generation. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pages 2157–2169.

- Liu, Bing and Ian Lane. 2016. Attention-based recurrent neural network models for joint intent detection and slot filling. In *Interspeech 2016*, pages 685–689.
- Liu, Shuman, Hongshen Chen, Zhaochun Ren, Yang Feng, Qun Liu, and Dawei Yin. 2018a. Knowledge diffusion for neural dialogue generation. In *ACL 2018: 56th Annual Meeting of the Association for Computational Linguistics*, volume 1, pages 1489–1498.
- Liu, Yahui, Wei Bi, Jun Gao, Xiaojiang Liu, Jian Yao, and Shuming Shi. 2018b. Toward less generic responses in neural conversation models: A statistical re-weighting method. In *EMNLP 2018: 2018 Conference on Empirical Methods in Natural Language Processing*, pages 2769–2774.
- Lowe, Ryan, Nissan Pow, Iulian Serban, and Joelle Pineau. 2015. The ubuntu dialogue corpus: A large dataset for research in unstructured multi-turn dialogue systems. In *Proceedings of the 16th Annual Meeting of the Special Interest Group on Discourse and Dialogue*, pages 285–294.
- Luo, Liangchen, Wenhao Huang, Qi Zeng, Xu Sun, and Zaiqing Nie. 2019. Learning personalized end-to-end goal-oriented dialog. *AAAI 2019 : Thirty-Third AAAI Conference on Artificial Intelligence*, 33:6794–6801.
- Mairesse, Francois and Marilyn Walker. 2007. Personage: Personality generation for dialogue. In *Proceedings of the 45th Annual Meeting of the Association of Computational Linguistics*, pages 496–503.
- Mesnil, Grégoire, Xiaodong He, Li Deng, and Yoshua Bengio. 2013. Investigation of recurrent-neural-network architectures and learning methods for spoken language understanding. In *INTERSPEECH*, pages 3771–3775.
- Mou, Lili, Yiping Song, Rui Yan, Ge Li, Lu Zhang, and Zhi Jin. 2016. Sequence to backward and forward sequences: A content-introducing approach to generative short-text conversation. In *COLING*, pages 3349–3358.
- Mrksic, Nikola, Diarmuid Ó Séaghdha, Tsung-Hsien Wen, Blaise Thomson, and Steve J. Young. 2017. Neural belief tracker: Data-driven dialogue state tracking. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, volume 1, pages 1777–1788.
- Mrkšić, Nikola, Diarmuid Ó Séaghdha, Blaise Thomson, Milica Gasic, Pei-Hao Su, David Vandyke, Tsung-Hsien Wen, and Steve Young. 2015. Multi-domain dialog state tracking using recurrent neural networks. In *Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 2: Short Papers)*, volume 2, pages 794–799.
- Pang, Liang, Yanyan Lan, Jiafeng Guo, Jun Xu, Shengxian Wan, and Xueqi Cheng. 2016. Text matching as image recognition. In *AAAI’16 Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence*, pages 2793–2799.
- Qu, Chen, Liu Yang, Minghui Qiu, W. Bruce Croft, Yongfeng Zhang, and Mohit Iyyer. 2019. Bert with history answer embedding for conversational question answering. In *Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval - SIGIR’19*, pages 1133–1136.

- Ravuri, Suman V. and Andreas Stolcke. 2015. Recurrent neural network and lstm models for lexical utterance classification. In *INTERSPEECH*, pages 135–139.
- Raymond, Christian and Giuseppe Riccardi. 2007. Generative and discriminative algorithms for spoken language understanding. In *INTERSPEECH*, pages 1605–1608.
- Reiter, Ehud. 1994. Has a consensus nl generation architecture appeared, and is it psycholinguistically plausible? In *INLG '94 Proceedings of the Seventh International Workshop on Natural Language Generation*, pages 163–170.
- Reiter, Ehud and Robert Dale. 2000. *Building Natural Language Generation Systems*.
- Ren, Hang, Weiqun Xu, Yan Zhang, and Yonghong Yan. 2013. Dialog state tracking using conditional random fields. In *Proceedings of the SIGDIAL 2013 Conference*, pages 457–461.
- Ritter, Alan, Colin Cherry, and William B. Dolan. 2011. Data-driven response generation in social media. In *Proceedings of the 2011 Conference on Empirical Methods in Natural Language Processing*, pages 583–593.
- Rudnicky, Alexander I., Eric H. Thayer, Paul C. Constantinides, Chris Tchou, R. Shern, Kevin A. Lenzo, W. Xu, and Alice Oh. 1999. Creating natural dialogs in the carnegie mellon communicator system. In *EUROSPEECH*.
- Sarikaya, Ruhi, Geoffrey E. Hinton, and Bhuvana Ramabhadran. 2011. Deep belief nets for natural language call-routing. In *2011 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5680–5683.
- Serban, Iulian V., Alessandro Sordoni, Yoshua Bengio, Aaron Courville, and Joelle Pineau. 2016. Building end-to-end dialogue systems using generative hierarchical neural network models. In *AAAI'16 Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence*, pages 3776–3783.
- Serban, Iulian Vlad, Alessandro Sordoni, Ryan Lowe, Laurent Charlin, Joelle Pineau, Aaron C. Courville, and Yoshua Bengio. 2017. A hierarchical latent variable encoder-decoder model for generating dialogues. In *AAAI*, pages 3295–3301.
- Shang, Lifeng, Zhengdong Lu, and Hang Li. 2015. Neural responding machine for short-text conversation. In *Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, volume 1, pages 1577–1586.
- Shao, Yuanlong, Stephan Gouws, Denny Britz, Anna Goldie, Brian Strope, and Ray Kurzweil. 2017. Generating high-quality and informative conversation responses with sequence-to-sequence models. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pages 2210–2219.
- Simonnet, Edwin, Nathalie Camelin, Paul Deléglise, and Yannick Estève. 2015. Exploring the use of attention-based recurrent neural networks for spoken language understanding.
- Song, Yiping, Cheng-Te Li, Jian-Yun Nie, Ming Zhang, Dongyan Zhao, and Rui Yan. 2018. An ensemble of retrieval-based and generation-based human-computer conversation systems. In *IJCAI 2018: 27th International Joint Conference on Artificial Intelligence*, pages 4382–4388.
- Sordoni, Alessandro, Michel Galley, Michael Auli, Chris Brockett, Yangfeng Ji, Margaret Mitchell, Jian-Yun Nie, Jianfeng Gao, and Bill Dolan. 2015. A neural network approach to context-sensitive generation of conversational responses. In *Proceedings of the 2015*

- Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 196–205.
- Su, Pei-Hao, Pawel Budzianowski, Stefan Ultes, Milica Gasic, and Steve J. Young. 2017. Sample-efficient actor-critic reinforcement learning with supervised data for dialogue management. In *Proceedings of the 18th Annual SIGdial Meeting on Discourse and Dialogue*, pages 147–157.
- Sutskever, Ilya, Oriol Vinyals, and Quoc V. Le. 2014. Sequence to sequence learning with neural networks. In *Advances in Neural Information Processing Systems 27*, pages 3104–3112.
- Tao, Chongyang, Wei Wu, Can Xu, Wenpeng Hu, Dongyan Zhao, and Rui Yan. 2019. Multi-representation fusion network for multi-turn response selection in retrieval-based chatbots. In *Proceedings of the Twelfth ACM International Conference on Web Search and Data Mining*, pages 267–275.
- Tian, Zhiliang, Rui Yan, Lili Mou, Yiping Song, Yansong Feng, and Dongyan Zhao. 2017. How to make context more useful? an empirical study on context-aware neural conversational models. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, volume 2, pages 231–236.
- Tur, Gokhan, Li Deng, Dilek Hakkani-Tur, and Xiaodong He. 2012. Towards deeper understanding: Deep convex networks for semantic utterance classification. In *2012 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5045–5048.
- Turing, A. M. 1950. I.—computing machinery and intelligence. *Mind*, 59(236):433–460.
- Wang, Hao, Zhengdong Lu, Hang Li, and Enhong Chen. 2013. A dataset for research on short-text conversations. In *Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing*, pages 935–945.
- Wang, Ye-Yi and Alex Acero. 2006. Discriminative models for spoken language understanding. In *INTERSPEECH*.
- Weizenbaum, Joseph. 1966. Eliza —a computer program for the study of natural language communication between man and machine. *Communications of The ACM*, 9(1):36–45.
- Wen, Tsung-Hsien, David Vandyke, Nikola Mrkšić, Milica Gasic, Lina M. Rojas Barahona, Pei-Hao Su, Stefan Ultes, and Steve Young. 2017. A network-based end-to-end trainable task-oriented dialogue system. In *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 1, Long Papers*, volume 1, pages 438–449.
- Wilensky, Robert, David N Chin, Marc Luria, James H. Martin, James Mayfield, and Dekai Wu. 1988. The berkeley unix consultant project. *Computational Linguistics*, 14(4):35–84.
- Williams, Jason. 2013. Multi-domain learning and generalization in dialog state tracking. In *Proceedings of the SIGDIAL 2013 Conference*, pages 433–441.
- Williams, Jason, Antoine Raux, Deepak Ramachandran, and Alan Black. 2013. The dialog state tracking challenge. In *Proceedings of the SIGDIAL 2013 Conference*, pages 404–413.
- Williams, Jason D. 2014. Web-style ranking and slu combination for dialog state tracking. In *Proceedings of the 15th Annual Meeting of the Special Interest Group on Discourse and*

- Dialogue (SIGDIAL)*, pages 282–291.
- Wu, Yu, Wei Wu, Chen Xing, Ming Zhou, and Zhoujun Li. 2017. Sequential matching network: A new architecture for multi-turn response selection in retrieval-based chatbots. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, volume 1, pages 496–505.
- Xing, Chen, Wei Wu, Yu Wu, Jie Liu, Yalou Huang, Ming Zhou, and Wei-Ying Ma. 2017. Topic aware neural response generation. In *AAAI*, pages 3351–3357.
- Xing, Chen, Yu Wu, Wei Wu, Yalou Huang, and Ming Zhou. 2018. Hierarchical recurrent attention network for response generation. In *AAAI-18 AAAI Conference on Artificial Intelligence*, pages 5610–5617.
- Xu, Puyang and Ruhi Sarikaya. 2013. Convolutional neural network based triangular crf for joint intent detection and slot filling. In *2013 IEEE Workshop on Automatic Speech Recognition and Understanding*, pages 78–83.
- Yan, Rui, Yiping Song, and Hua Wu. 2016. Learning to respond with deep neural networks for retrieval-based human-computer conversation system. In *Proceedings of the 39th International ACM SIGIR conference on Research and Development in Information Retrieval*, pages 55–64.
- Yao, Kaisheng, Geoffrey Zweig, Mei-Yuh Hwang, Yangyang Shi, and Dong Yu. 2013. Recurrent neural networks for language understanding. In *INTERSPEECH*, pages 2524–2528.
- Young, Tom, Erik Cambria, Iti Chaturvedi, Minlie Huang, Hao Zhou, and Subham Biswas. 2018. Augmenting end-to-end dialogue systems with commonsense knowledge. In *AAAI-18 AAAI Conference on Artificial Intelligence*, pages 4970–4977.
- Zhai, Feifei, Saloni Potdar, Bing Xiang, and Bowen Zhou. 2017. Neural models for sequence chunking. In *AAAI*, pages 3365–3371.
- Zhang, Saizheng, Emily Dinan, Jack Urbanek, Arthur Szlam, Douwe Kiela, and Jason Weston. 2018a. Personalizing dialogue agents: I have a dog, do you have pets too? In *ACL 2018: 56th Annual Meeting of the Association for Computational Linguistics*, volume 1, pages 2204–2213.
- Zhang, Wei-Nan, Qingfu Zhu, Yifa Wang, Yanyan Zhao, and Ting Liu. 2019. Neural personalized response generation as domain adaptation. *World Wide Web*, 22(4):1427–1446.
- Zhang, Zhuosheng, Jiangtong Li, Pengfei Zhu, and Hai Zhao. 2018b. Modeling multi-turn conversation with deep utterance aggregation. In *COLING 2018: 27th International Conference on Computational Linguistics*, pages 3740–3752.
- Zhao, Tiancheng and Maxine Eskenazi. 2016. Towards end-to-end learning for dialog state tracking and management using deep reinforcement learning. In *Proceedings of the 17th Annual Meeting of the Special Interest Group on Discourse and Dialogue*, pages 1–10.
- Zheng, Yinhe, Guanyi Chen, Minlie Huang, Song Liu, and Xuan Zhu. 2019. Personalized dialogue generation with diversified traits. *arXiv preprint arXiv:1901.09672*.
- Zhou, Hao, Tom Young, Minlie Huang, Haizhou Zhao, Jingfang Xu, and Xiaoyan Zhu. 2018. Commonsense knowledge aware conversation generation with graph attention. In *IJCAI 2018: 27th International Joint Conference on Artificial Intelligence*, pages 4623–4629.

- Zhou, Jianshe, Peng Chen, Yan Zhao, Ming Zhou, Nan Duan, and Zhoujun Li. 2017. Building task-oriented dialogue systems for online shopping. In *AAAI*, pages 4618–4626.
- Zhou, Li, Jianfeng Gao, Di Li, and Heung-Yeung Shum. 2018. The design and implementation of xiaoice, an empathetic social chatbot.
- Zhou, Xiangyang, Daxiang Dong, Hua Wu, Shiqi Zhao, Dianhai Yu, Hao Tian, Xuan Liu, and Rui Yan. 2016. Multi-view response selection for human-computer conversation. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pages 372–381.
- Zhou, Xiangyang, Lu Li, Daxiang Dong, Yi Liu, Ying Chen, Wayne Xin Zhao, Dianhai Yu, and Hua Wu. 2018. Multi-turn response selection for chatbots with deep attention matching network. In *ACL 2018: 56th Annual Meeting of the Association for Computational Linguistics*, volume 1, pages 1118–1127.
- Zue, V., S. Seneff, J.R. Glass, J. Polifroni, C. Pao, T.J. Hazen, and L. Hetherington. 2000. Juplter: a telephone-based conversational interface for weather information. *IEEE Transactions on Speech and Audio Processing*, 8(1):85–96.
- Zue, V.W. and J.R. Glass. 2000. Conversational interfaces: advances and challenges. *Proceedings of the IEEE*, 88(8):1166–1180.

